

Clustering

Mezclas de Gaussianas

Christian Oliva Moya

Dpto. de Ingeniería Informática, Escuela Politécnica Superior

Universidad Autónoma de Madrid

28049 Madrid, Spain

Índice

1. Introducción
2. Teorema de Bayes
3. Teorema de Bayes para E-M
4. Algoritmo E-M
 - a. Paso 1: Expectation
 - b. Paso 2: Maximization
 - c. Notebook

Introducción (1)

- **Expectation-Maximization** (E-M) describe probabilísticamente los grupos

K-means asume que los datos se organizan en K grupos según los centroides (medias).

E-M asume K distribuciones estadísticas (Gaussianas: medias + varianzas).

- Es un algoritmo **estocástico** (iterativo), como K-means.


Comienza con parámetros aleatorios e itera hasta converger.

- Es un algoritmo **difuso** (soft).

Un punto puede pertenecer a varios clusters (probabilidades).

Introducción (2)

- Ejemplo de ejecución:
 - Se forman $K=3$ Gaussianas (solapadas)
 - Cada una con media y varianza diferentes



Introducción (3)

- Nomenclatura:

- Conjunto de n elementos $X = (x_1, x_2, \dots, x_n)$ con dimensión 1

- Asumimos que existen k Gaussianas $G = (G_1, G_2, \dots, G_k)$

Con sus respectivos parámetros $\mu = (\mu_1, \mu_2, \dots, \mu_k)$ y $\sigma^2 = (\sigma_1^2, \sigma_2^2, \dots, \sigma_k^2)$

Teorema de Bayes

$$P(G_j|x_i) = \frac{P(x_i|G_j)P(G_j)}{P(x_i)}$$

- Donde:

- $P(G_j | x_i)$ es la probabilidad de que x_i pertenezca a $G_j \rightarrow$ Probabilidad a posteriori
- $P(G_j)$ es la probabilidad de pertenecer a la gaussiana $G_j \rightarrow$ Probabilidad a priori
- $P(x_i)$ es la probabilidad de seleccionar el elemento $x_i \rightarrow$ Evidencia
- $P(x_i | G_j)$ es la verosimilitud (likelihood), que sigue una distribución gaussiana:

$$P(x_i|G_i) = \frac{1}{\sqrt{2\pi\sigma_j^2}} \exp\left(-\frac{(x_i - \mu_j)^2}{2\sigma_j^2}\right)$$

Teorema de Bayes para E-M (1)

$$P(G_j|x_i) = \frac{P(x_i|G_j)P(G_j)}{P(x_i)}$$

$$P(x_i|G_j) = \frac{1}{\sqrt{2\pi\sigma_j^2}} \exp\left(-\frac{(x_i - \mu_j)^2}{2\sigma_j^2}\right)$$

- Asumimos los siguientes puntos:

- $P(G_j)$ es la probabilidad de pertenecer a la gaussiana $G_j \rightarrow$ Probabilidad a priori

No conocemos los prioris $\rightarrow P(G_j) = 1 / K$ para todas las gaussianas.

- $P(x_i)$ es la probabilidad de seleccionar el elemento $x_i \rightarrow$ Evidencia

La probabilidad de cada punto es igual para todos $\rightarrow P(x_i) = 1 / n$ para todos los puntos.

Teorema de Bayes para E-M (2)

- Ejemplo:

$X = (x_1 = 3, x_2 = 2, x_3 = -3, x_4 = -2)$ y $K = 2$

$G_1 = (\mu_1 = 2.0, \sigma_1 = 1.0)$ y $G_2 = (\mu_2 = -2.0, \sigma_2 = 1.0)$

Calculamos los prioris y las evidencias:

$$P(G_j|x_i) = \frac{P(x_i|G_j)P(G_j)}{P(x_i)}$$

$$P(x_i|G_i) = \frac{1}{\sqrt{2\pi\sigma_j^2}} \exp\left(-\frac{(x_i - \mu_j)^2}{2\sigma_j^2}\right)$$

Teorema de Bayes para E-M (2)

- Ejemplo:

$X = (x_1 = 3, x_2 = 2, x_3 = -3, x_4 = -2)$ y $K = 2$

$G_1 = (\mu_1 = 2.0, \sigma_1 = 1.0)$ y $G_2 = (\mu_2 = -2.0, \sigma_2 = 1.0)$

Calculamos los prioris y las evidencias:

$$P(G_1) = P(G_2) = 1 / 2 = 0.5$$

$$P(x_1) = P(x_2) = P(x_3) = P(x_4) = 1 / 4 = 0.25$$

Calculamos verosimilitudes G1:

Calculamos verosimilitudes G2:

$$P(G_j|x_i) = \frac{P(x_i|G_j)P(G_j)}{P(x_i)}$$

$$P(x_i|G_j) = \frac{1}{\sqrt{2\pi\sigma_j^2}} \exp\left(-\frac{(x_i - \mu_j)^2}{2\sigma_j^2}\right)$$

Teorema de Bayes para E-M (2)

- Ejemplo:

$X = (x_1 = 3, x_2 = 2, x_3 = -3, x_4 = -2)$ y $K = 2$

$G_1 = (\mu_1 = 2.0, \sigma_1 = 1.0)$ y $G_2 = (\mu_2 = -2.0, \sigma_2 = 1.0)$

Calculamos los prioris y las evidencias:

$$P(G_1) = P(G_2) = 1 / 2 = 0.5$$

$$P(x_1) = P(x_2) = P(x_3) = P(x_4) = 1 / 4 = 0.25$$

Calculamos verosimilitudes G1:

$$P(x_1 | G_1) = \dots = 0.241971$$

$$P(x_2 | G_1) = \dots = 0.398942$$

$$P(x_3 | G_1) = \dots = 0.000001$$

$$P(x_4 | G_1) = \dots = 0.000134$$

Calculamos verosimilitudes G2:

$$P(x_1 | G_2) = \dots = 0.000001$$

$$P(x_2 | G_2) = \dots = 0.000134$$

$$P(x_3 | G_2) = \dots = 0.241971$$

$$P(x_4 | G_2) = \dots = 0.398942$$

$$P(G_j | x_i) = \frac{P(x_i | G_j)P(G_j)}{P(x_i)}$$

$$P(x_i | G_j) = \frac{1}{\sqrt{2\pi\sigma_j^2}} \exp\left(-\frac{(x_i - \mu_j)^2}{2\sigma_j^2}\right)$$

Calculamos las probabilidades:

Teorema de Bayes para E-M (2)

- Ejemplo:

$X = (x_1 = 3, x_2 = 2, x_3 = -3, x_4 = -2)$ y $K = 2$

$G_1 = (\mu_1 = 2.0, \sigma_1 = 1.0)$ y $G_2 = (\mu_2 = -2.0, \sigma_2 = 1.0)$

Calculamos los prioris y las evidencias:

$$P(G_1) = P(G_2) = 1 / 2 = 0.5$$

$$P(x_1) = P(x_2) = P(x_3) = P(x_4) = 1 / 4 = 0.25$$

Calculamos verosimilitudes G1:

$$P(x_1 | G_1) = \dots = 0.241971$$

$$P(x_2 | G_1) = \dots = 0.398942$$

$$P(x_3 | G_1) = \dots = 0.000001$$

$$P(x_4 | G_1) = \dots = 0.000134$$

Calculamos verosimilitudes G2:

$$P(x_1 | G_2) = \dots = 0.000001$$

$$P(x_2 | G_2) = \dots = 0.000134$$

$$P(x_3 | G_2) = \dots = 0.241971$$

$$P(x_4 | G_2) = \dots = 0.398942$$

$$P(G_j | x_i) = \frac{P(x_i | G_j)P(G_j)}{P(x_i)}$$

$$P(x_i | G_j) = \frac{1}{\sqrt{2\pi\sigma_j^2}} \exp\left(-\frac{(x_i - \mu_j)^2}{2\sigma_j^2}\right)$$

Calculamos las probabilidades:

$$P(G_1 | x_1) = \dots = 0.483941$$

$$P(G_1 | x_2) = \dots = 0.797884$$

$$P(G_1 | x_3) = \dots = 0.000003$$

$$P(G_1 | x_4) = \dots = 0.000268$$

$$P(G_2 | x_1) = \dots = 0.000003$$

$$P(G_2 | x_2) = \dots = 0.000268$$

$$P(G_2 | x_3) = \dots = 0.483941$$

$$P(G_2 | x_4) = \dots = 0.797884$$

Teorema de Bayes para E-M (3)

- Ejemplo:

- Asignamos al cluster con mayor probabilidad:

$$P(G_1 | x_1) = \dots = 0.483941 \rightarrow 0.999999$$

$$P(G_2 | x_1) = \dots = 0.000003 \rightarrow 0.000001$$

$$P(G_1 | x_2) = \dots = 0.797884 \rightarrow 0.999664$$

$$P(G_2 | x_2) = \dots = 0.000268 \rightarrow 0.000336$$

$$P(G_1 | x_3) = \dots = 0.000003 \rightarrow 0.000001$$

$$P(G_2 | x_3) = \dots = 0.483941 \rightarrow 0.999999$$

$$P(G_1 | x_4) = \dots = 0.000268 \rightarrow 0.000336$$

$$P(G_2 | x_4) = \dots = 0.797884 \rightarrow 0.999664$$

Teorema de Bayes para E-M (4)

$$P(G_j|x_i) = \frac{P(x_i|G_j)P(G_j)}{P(x_i)}$$

- Hemos asumido que:
 - No conocemos los prioris $\rightarrow P(G_j) = 1 / K$ para todas las gaussianas.
 - La probabilidad de cada punto es igual para todos $\rightarrow P(x_i) = 1 / n$ para todos los puntos.
- ¿Podemos inferir lo siguiente?

$$P(G_j|x_i) = P(x_i|G_j)$$

OJO!! Solamente en E-M para clustering!!

Teorema de Bayes para E-M (5)

- Ejemplo:

| | | | | |
|-----------------------------------|---------------|----------|--------------|-----------------------------------|
| $P(G_1 x_1) = \dots = 0.483941$ | \rightarrow | 0.999999 | \leftarrow | $P(x_1 G_1) = \dots = 0.241971$ |
| $P(G_2 x_1) = \dots = 0.000003$ | \rightarrow | 0.000001 | \leftarrow | $P(x_1 G_2) = \dots = 0.000001$ |
| $P(G_1 x_2) = \dots = 0.797884$ | \rightarrow | 0.999664 | \leftarrow | $P(x_2 G_1) = \dots = 0.398942$ |
| $P(G_2 x_2) = \dots = 0.000268$ | \rightarrow | 0.000336 | \leftarrow | $P(x_2 G_2) = \dots = 0.000134$ |
| $P(G_1 x_3) = \dots = 0.000003$ | \rightarrow | 0.000001 | \leftarrow | $P(x_3 G_1) = \dots = 0.000001$ |
| $P(G_2 x_3) = \dots = 0.483941$ | \rightarrow | 0.999999 | \leftarrow | $P(x_3 G_2) = \dots = 0.241971$ |
| $P(G_1 x_4) = \dots = 0.000268$ | \rightarrow | 0.000336 | \leftarrow | $P(x_4 G_1) = \dots = 0.000134$ |
| $P(G_2 x_4) = \dots = 0.797884$ | \rightarrow | 0.999664 | \leftarrow | $P(x_4 G_2) = \dots = 0.398942$ |

Algoritmo E-M (1)

- Inicializar de forma aleatoria las gaussianas. Por ejemplo:

Los K puntos de partida son puntos del dataset seleccionados al azar.

Se calculan las K medias y varianzas de los datos más cercanos a cada punto de partida.

- Mientras no converja el algoritmo:
 - Paso 1: Expectation (asignación a grupos)
 - Paso 2: Maximization (actualización de medias y varianzas)

Algoritmo E-M (2) – Paso 1

- **Expectation:** Asignar cada elemento x_i al grupo S_j cuya verosimilitud sea máxima.

$$P(x_i|G_i) = \frac{1}{\sqrt{2\pi\sigma_j^2}} \exp\left(-\frac{(x_i - \mu_j)^2}{2\sigma_j^2}\right)$$

$$\theta_{ij} = P(G_j|x_i) = \frac{P(x_i|G_j)P(G_j)}{P(x_i)}$$

$$S_j = S_j \cup \{ \text{argMax}(\theta_{ij}) \text{ for each } j \text{ in range}(K) \}$$

Algoritmo E-M (2) – Paso 2

- **Maximization.** Recalcular los parámetros para cada G_j

$$\mu_j^{(t+1)} = \frac{\sum \theta_{ij}^{(t)} x_i}{\sum \theta_{ij}^{(t)}} \quad \sigma_j^{2:(t+1)} = \frac{\sum \theta_{ij}^{(t)} (x_i - \mu_j^{(t+1)})^2}{\sum \theta_{ij}^{(t)}}$$

Algoritmo E-M (3) – Notebook

- Algoritmo E-M en python:
 - Notebook 04_ejemplo_EM.ipynb